

INFORME ÉTICO Y DE GOBERNANZA

Modelo de Predicción de Churn — Dataset Olist

Proyecto	Predicción de Churn — E-commerce Olist
Grupo	Grupo 7 — Percy Fuentes
Sprint	Sprint 4 — Modelo Final
Fecha	20 de June de 2026

1. Introducción y Contexto

El presente informe analiza las implicaciones éticas, de privacidad y de gobernanza del modelo de predicción de churn desarrollado sobre el dataset público de Olist, una plataforma de e-commerce brasileña. El modelo predice qué clientes tienen mayor probabilidad de abandonar la plataforma en el siguiente mes, utilizando su historial de comportamiento de compra.

Un modelo predictivo de esta naturaleza puede tener impactos directos sobre personas reales —los clientes— al determinar quiénes reciben ofertas de retención, descuentos o atención prioritaria. Por ello, es fundamental evaluar su uso desde una perspectiva ética y de responsabilidad.

Modelo final: Logistic Regression (LogReg) | AUC Live: 63% | Lift Decil 1: 2.24x | 27 variables de comportamiento | Datos: Olist 2016-2018 (público, Kaggle)

2. Transparencia y Explicabilidad

2.1 Elección de modelo interpretable

Se eligió Logistic Regression como modelo final, en lugar de modelos de mayor complejidad como Gradient Boosting (HGB), precisamente por su interpretabilidad nativa. Los coeficientes del modelo permiten explicar directamente la dirección e impacto de cada variable sobre la predicción.

2.2 Herramientas de explicabilidad aplicadas

- **Coeficientes LogReg:** Coeficientes normalizados: importancia relativa de cada variable (max 11.57% para comprador_unico).
- **SHAP:** SHAP LinearExplainer: valores SHAP por cliente, beeswarm y bar plots.
- **Permutation Importance:** Permutation Importance: validación cruzada de la importancia de features.
- **Gain & Lift:** Gain/Lift Tables: cuantificación del poder de discriminación por deciles.

2.3 Narrativa explicable para el negocio

El modelo puede comunicarse a equipos no técnicos de la siguiente manera:

Un cliente tiene mayor riesgo de churn si: lleva mucho tiempo sin comprar (recencia alta), compra siempre en la misma categoría (comprador_unico alto), recibe pedidos tarde (lead_min alto) y usa muchas cuotas (installments_max alto). Por el contrario, compras frecuentes y buenas reseñas reducen el riesgo.

3. Análisis de Sesgos Potenciales

3.1 Sesgo de selección temporal

El modelo fue entrenado con datos de 2016 a enero 2018, período de rápido crecimiento de Olist. Los patrones de comportamiento del cliente en ese período pueden no representar fielmente el comportamiento en períodos más recientes o en otras etapas del ciclo de vida del negocio.

- **Mitigación:** Se implementaron tres períodos de validación independientes (Val, BackTest, Live) para detectar degradación temporal.
- **Resultado:** El AUC mejora progresivamente (59.8% → 61% → 63%), indicando que el modelo no sobreaprende el período histórico.

3.2 Sesgo por clase desbalanceada

El dataset presenta un fuerte desbalance: churn=0 (clientes que abandonan) representa solo el 1.2% del total, mientras que churn=1 (clientes activos) es el 98.8%. Sin corrección, el modelo tendería a ignorar la clase minoritaria.

- **Mitigación:** Se aplicó SMOTE (oversampling) + RandomUnderSampler para balancear las clases durante el entrenamiento.
- **Métrica:** La evaluación se realizó con AUC-ROC, métrica robusta ante desbalance.

3.3 Sesgo de variables proxy

Variables como installments_max (uso de cuotas) o freight_total_sum (costo de flete) pueden actuar como proxies de condición socioeconómica del cliente. El uso de estas variables para decisiones de retención podría resultar en tratamiento diferenciado basado indirectamente en el nivel de ingresos.

- **Recomendación:** Monitorear que las tasas de predicción de churn no difieran significativamente entre regiones geográficas del Brasil.
- **Futuro:** Evaluar impacto diferencial por segmento de cliente en futuras iteraciones.

3.4 Sesgo de data leakage corregido

Durante el desarrollo se detectó y corrigió un data leakage en la variable lead_min: se utilizaba la fecha de entrega real (posterior al corte temporal T) para calcular el tiempo de entrega mínimo. Tras la corrección, la importancia de lead_min bajó de ~20% a ~7%, reflejando su contribución real.

La corrección del leakage es un ejemplo de práctica ética: el modelo no debe usar información del futuro para predecir el presente, ya que esto generaría predicciones irreproducibles en producción real.

4. Privacidad y Cumplimiento LGPD

4.1 Marco legal aplicable

El dataset corresponde a clientes de Olist en Brasil. La Lei Geral de Proteção de Dados Pessoais (LGPD, Lei nº 13.709/2018) regula el tratamiento de datos personales en Brasil, con principios equivalentes al GDPR europeo. Entró en vigor en agosto de 2020 con sanciones desde agosto de 2021.

4.2 Datos utilizados y su clasificación

Variable / Grupo	Tipo de dato	Clasificación LGPD
customer_unique_id	Identificador anonimizado	Dato personal seudonimizado
Historial de órdenes	Fechas, montos, categorías	Dato personal — comportamiento
review_max / buenas	Calificaciones de productos	Dato personal — opinión
lead_min, freight_*	Tiempos y costos de entrega	Dato operacional — no sensible
customer_zip_prefix	Prefijo de código postal	Dato personal — ubicación aproximada

4.3 Principios LGPD aplicados

- **Anonimización:** El dataset de Olist es público (Kaggle). customer_unique_id es un hash que no permite reidentificación directa.
- **Minimización de datos:** Las variables seleccionadas son de comportamiento de compra, no datos sensibles (salud, religión, biometría).
- **Finalidad:** El modelo predice comportamiento futuro basado exclusivamente en historial de compras del propio cliente.
- **Uso académico:** El dataset se usa únicamente para el desarrollo del modelo académico, no para decisiones comerciales reales.

4.4 Consideraciones para producción real

Si este modelo se desplegara en un entorno productivo real, sería necesario:

- Obtener base legal explícita (consentimiento o legítimo interés) para el tratamiento predictivo.
- Implementar el derecho de explicación: el cliente afectado por una decisión automatizada tiene derecho a conocer los motivos.
- Registrar el tratamiento de datos en el Registro de Atividades de Tratamento (RAT).
- Designar un Encarregado de Proteção de Dados (DPO) si el volumen de tratamiento lo requiere.
- Realizar una Avaliação de Impacto à Proteção de Dados (AIPD) antes del despliegue.

5. Uso Responsable del Modelo

5.1 Usos permitidos y recomendados

- Priorizar clientes para campañas de retención proactiva (descuentos, contacto personalizado).
- Segmentar la base de clientes por nivel de riesgo para optimizar el presupuesto de marketing.
- Identificar factores operacionales que aumentan el churn (ej: tiempos de entrega) para mejorar el servicio.
- Monitoreo continuo de la salud de la base de clientes.

5.2 Usos NO recomendados

- Negar servicios o beneficios a clientes clasificados como "churn alto" — el modelo predice probabilidad, no certeza.
- Usar las predicciones como criterio único de decisión sin revisión humana.
- Aplicar el modelo a segmentos de clientes muy diferentes al perfil de entrenamiento (ej: clientes B2B vs B2C).
- Compartir predicciones individuales con terceros sin base legal.

Principio clave: El modelo es una herramienta de apoyo a la decisión, no un sustituto del juicio humano. Un score alto de churn debe iniciar una conversación con el cliente, no una acción automatizada irreversible.

6. Gobernanza y Plan de Monitoreo

6.1 Indicadores de monitoreo en producción

Indicador	Umbral de alerta	Acción recomendada
AUC en producción	Caída > 5 puntos vs Live (63%)	Reentrenamiento inmediato
PSI de features	PSI > 0.25 en cualquier variable	Revisar distribución + reentrenar
Tasa de churn observada	Desviación > 2% vs histórico 1.2%	Análisis de causa raíz
Lift Decil 1	Lift < 1.5x en período reciente	Revisión del modelo

6.2 Ciclo de reentrenamiento

- Frecuencia recomendada: mensual, con los datos del mes más reciente.
- Criterio de reentrenamiento obligatorio: PSI > 0.25 o caída de AUC > 5 puntos.
- Evaluación en BackTest y Live antes de desplegar cada nueva versión.
- Versionado del modelo: guardar pickle con fecha y métricas de evaluación.

6.3 Responsabilidades

- **Data Scientist:** Científico de datos: mantenimiento del modelo, monitoreo de métricas, reentrenamiento.
- **Negocio:** Equipo de negocio: definición de acciones de retención, validación de resultados en campo.
- **DPO:** DPO (si aplica): supervisión del cumplimiento LGPD, auditorías de uso del modelo.
- **Dirección:** Alta dirección: aprobación del uso del modelo para decisiones de alto impacto.

7. Limitaciones del Modelo

- **Capacidad predictiva:** AUC de 63% indica capacidad predictiva moderada. El modelo no predice con certeza, solo estima probabilidades.

- **Representatividad:** Datos de 2016-2018 de una plataforma brasileña en crecimiento. Puede no generalizar a otros mercados o períodos.
- **Variables externas:** El modelo no captura eventos externos (crisis económica, competencia nueva, cambios de política) que impacten el churn.
- **Desbalance extremo:** La tasa de churn del 1.2% es muy baja — pequeños errores de clasificación tienen gran impacto en métricas de precisión.
- **Impacto económico:** El CLV y el costo de campaña usados en el análisis económico son estimaciones de mercado, no valores reales de Olist.

8. Conclusiones y Recomendaciones

El modelo de churn desarrollado cumple con los principios éticos fundamentales para sistemas de machine learning aplicados a datos de clientes:

- **Transparente:** utiliza Logistic Regression con coeficientes interpretables y análisis SHAP.
- **Honesto:** evaluación en tres períodos independientes sin contaminación metodológica.
- **Robusto:** corrige data leakage, controla overfitting y valida estabilidad temporal.
- **Accionable:** Lift 2.24x permite campañas de retención 2x más eficientes que la selección aleatoria.

Para un despliegue responsable en producción, se recomienda implementar el plan de monitoreo descrito en la Sección 6, obtener las bases legales LGPD correspondientes y mantener siempre la supervisión humana sobre las decisiones de retención de clientes.

El modelo es un punto de partida, no un oráculo. Su valor real está en orientar recursos hacia los clientes con mayor riesgo, no en reemplazar el criterio humano ni en automatizar decisiones que afecten derechos de los clientes.